数据流水线使用说明（徐毅专用）

> 脚本由 Claude 写好并已用合成数据端到端跑通；你负责：跑通 → 检查结果合理 → 交 outputs/。 **零第三方依赖**：只要电脑上有 python3（macOS 自带），不用装任何库。

0. 环境检查（1 分钟）

终端（Terminal）里执行：

```
python3 --version    # 显示 3.8 以上就行
```

1. 目录约定

```
scripts/
├── explore_data.py / build_benchmark.py / synthesize_curve.py /
verify_monotonic.py / make_synthetic_base.py
├── data/raw/          ← 你把下载的 ad_performance.csv 放这里（文件夹没有就手动建）
└── outputs/           ← 所有结果自动生成在这里（不用建）
```

所有命令都在 scripts 文件夹里执行（终端先 `cd` 到这个文件夹）。

2. 执行顺序（5 条命令）

步	命令	干什么	产出
①	（手动）下载飞桨数据集放到 data/raw/	aistudio.baidu.com/datasetdetail/55268，注册百度账号后免费下载	data/raw/ad_performance.csv
②	`python3 explore_data.py`	字段/缺失/分组规模/率刻度探查	outputs/01-探查报告.md
③	`python3 build_benchmark.py`	分组统计转化端基准（均值+P25/P50/P75）	outputs/02-基准表-转化端.csv + draft.md
④	`python3 synthesize_curve.py`	合成曝光端基准（CTR/CPM/CPC）+ 出价梯度曲线	outputs/03、04 两个 csv + draft.md
⑤	`python3 verify_monotonic.py`	单调性 + 全表 sanity 校验	outputs/05-校验报告.md，**全 PASS 才算过**

⏱ 截止：①–② 9/9；③–⑤ 9/10。

3. 每步你要人工看什么（QC）

- **②之后**：打开 01-探查报告 → 看"三、率刻度判定"和"五、交叉分组规模" → 在"六、人工判断"补 2–3 句 + 勾数据来源。

- **③之后**：从 02 的 CSV 里**随机抽 1 个组**，用 Excel 筛出原始数据手算一个均值，和表对上才算数（防脚本错）。
- **④之后**：打开 draft.md 看"演算示例"（500 元预算那段），数字要能对上你的直觉量级。
- **⑤之后**：校验报告必须**全 PASS**。有 FAIL → 把报告发给队长，**不要手工改数字**。

4. 兜底：飞桨下载失败怎么办

1. `python3 make_synthetic_base.py` → 生成 data/raw/ad_performance_synthetic.csv
2. 用文本编辑器打开 explore_data.py 和 build_benchmark.py，把顶部 `INPUT_CSV = "..."` 改成 `data/raw/ad_performance_synthetic.csv`
3. 照常执行 ②→⑤，**并在探查报告人工判断里声明"数据来源=合成"**（答辩口径同步告诉队长）

5. 常见问题

- **"未识别到的业务列"不是"无"** → 真实 CSV 列名可能和预期不同：打开 explore_data.py 顶部 `ALIASES`，把真实列名加进对应候选列表（英文/异名都行），重跑。
- **解码失败** → 用 Excel 另存为"CSV UTF-8"再放回 data/raw/。
- **率数字很大（如 5.0）** → 脚本会自动判定百分数刻度并 ÷100，报告第三节有说明，确认一下即可。

6. 交什么给队长

outputs/ 里全部 6 个文件（01–05 + draft）打包；探查报告的人工判断写好；有 FAIL 附你的复现命令。